CP462 · INTRODUCTION TO DATA SCIENCE

HealthSense

Predicting Chronic Disease Risk from Daily Lifestyle

นำเสนอโดย
นายวัชรพงศ์ มาลัง 67102010174
นาย นราธิป สุวณิชย์ 67102010517

ที่มา

เราจะทำนายความเสี่ยงโรคเรื้อรังจากพฤติกรรมประจำวันยังไง

1

ปัจจัยทางประชากรศาสตร์และชีวภาพ:

เพศ (gender) และอายุ (age) ซึ่งสัมพันธ์กับความเสื่อมของร่างกายและการเปลี่ยนแปลงของระบบเผาผลาญตามวัย

2

โรคประจำตัวร่วม (Co-morbidities)

ภาวะความดันโลหิตสูง (hypertension) และโรคหัวใจ (heart_disease) ซึ่งมักพบร่วมกับภาวะดื้ออินซูลินและโรคระบบหลอดเลือด

3

พฤติกรรมสุขภาพและวิถีชีวิต

ประวัติการสูบบุหรี่ (smoking_history) และดัชนีมวลกาย (bmi) ซึ่งสะท้อนถึงภาวะอ้วนและพฤติกรรมการดำรงชีวิตที่เป็นปัจจัยเสี่ยงหลัก

ผู้ได้ประโยชน์

ใครได้ประโยชน์ และได้อย่างไร

1

ประชาชนทั่วไป

ประเมินความเสี่ยงเบาหวานของตัวเองจากข้อมูลพฤติกรรมประจำวัน ตัดสินใจปรับพฤติกรรมก่อนป่วยจริง

2

หน่วยงานสาธารณสุข

คัดกรองกลุ่มเสี่ยงสูงในพื้นที่ได้แม่นยำขึ้น จัดสรรทรัพยากรตรวจคัดกรองเชิงรุกได้ตรงกลุ่มเป้าหมาย

3

บริษัทประกันสุขภาพ

ใช้ปัจจัยเสี่ยงประกอบการประเมินความเสี่ยงลูกค้าและออกแบบโปรแกรมส่งเสริมสุขภาพเชิงป้องกัน

เป้าหมายที่วัดผลได้: ใช้ผลลัพธ์จากโมเดล เป็นสัญญาณเตือนล่วงหน้า เพื่อลดสัดส่วนผู้ป่วยที่ตรวจพบโรคช้า และเพิ่มอัตราการเข้าคัดกรองก่อนมีอาการ

ชุดข้อมูล

ชุดข้อมูลที่ใช้

Diabetes Prediction Dataset

แหล่งที่มา: Kaggle
(iammustafatz/diabetes-prediction-dataset)
(cross-sectional data - April 2023)

100,000

แถว (1 แถว = ผู้ป่วย 1 คน)

9

คอลัมน์ (8 features + 1 target)

จุดประสงค์: วิเคราะห์ความสัมพันธ์ระหว่างพฤติกรรม/สุขภาพกับเบาหวาน แล้วนำไปสร้างโมเดลทำนายความเสี่ยงใน Part 2

คอลัมน์	ความหมาย	ชนิด
gender	เพศ (Male/Female/Other)	Categorical
age	อายุ (0–80 ปี)	Numeric
hypertension	ความดันโลหิตสูงหรือไม่	Binary
heart_disease	โรคหัวใจหรือไม่	Binary
smoking_history	ประวัติการสูบบุหรี่	Categorical
bmi	ดัชนีมวลกาย	Numeric
HbA1c_level	น้ำตาลสะสม 2–3 เดือน	Numeric
blood_glucose_level	น้ำตาลในเลือดขณะตรวจ	Numeric
diabetes	Target: เป็นเบาหวาน (1/0)	Binary

ทำความสะอาดข้อมูล

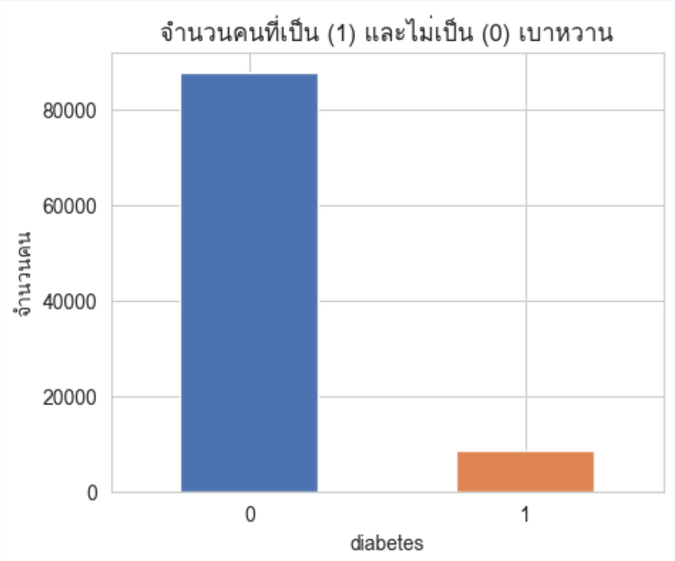
การทำความสะอาดข้อมูลที่สำคัญ

#	พบปัญหา	รายละเอียดที่พบ	วิธีจัดการ / เหตุผล
1	Missing (NaN)	ตรวจสอบทุกคอลัมน์ — ไม่พบค่า NaN เลย	ไม่ต้องแก้ไข ข้อมูลครบ 100%
2	Missing ที่ซ่อนอยู่	smoking_history มีค่า "No Info" 35,816 แถว (35.82%)	แปลงเป็น category "unknown" แทนการลบ เพื่อไม่เสียข้อมูลแถวอื่น
3	แถวซ้ำ (Duplicates)	พบ 3,854 แถวซ้ำ จาก 100,000 แถว	ลบด้วย drop_duplicates() เหลือ 96,146 แถว
4	Outlier ของ BMI	ตรวจด้วย Boxplot ช่วงข้อมูลจริง 10.01–95.69	ไม่มีค่าที่ผิดปกติแบบสุดโต่ง จึงไม่ตัดออก
5	ชนิดข้อมูล (dtype)	gender, smoking_history, hypertension, heart_disease, diabetes เป็น object/int	แปลงเป็น category ให้เหมาะกับการวิเคราะห์และสร้างกราฟ

ผลกระทบรวม: 100,000 แถวก่อนทำความสะอาด → 96,146 แถวหลังทำความสะอาด (ลบซ้ำ 3,854 แถว, ไม่มีการลบเนื่องจาก missing)

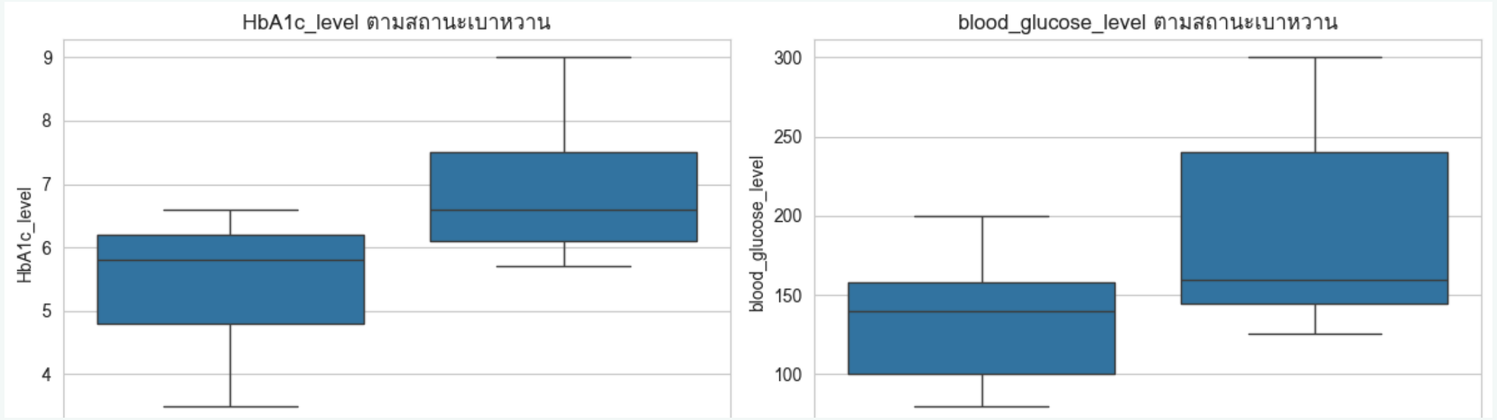
EDA (1/2)

ข้อมูลไม่สมดุล และตัวชี้วัดทางคลินิกแยกกลุ่มได้ชัดเจน



กราฟ 1 · สัดส่วนเป็น/ไม่เป็นเบาหวาน

ข้อมูล **imbalanced ชัดเจน** —แต่ "เดาว่าไม่เป็นเบาหวาน" ตลอดแล้วได้ accuracy สูงลวงตา ต้องมีการจัดการ เช่น oversampling, undersampling หรือปรับ class weight ในขั้น modeling



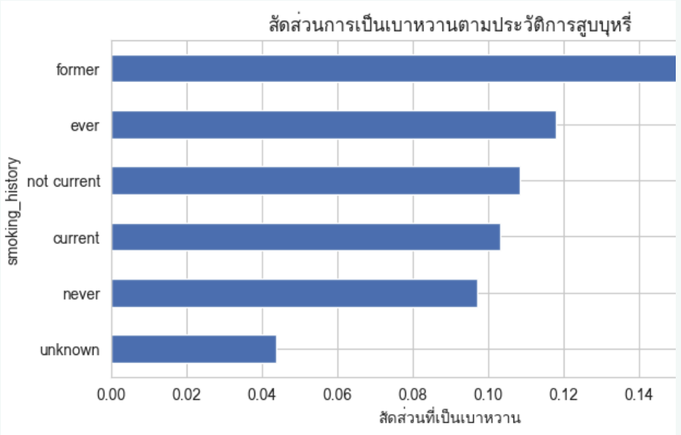
กราฟ 2 · HbA1c_level และ blood_glucose_level ตามสถานะเบาหวาน

กลุ่มที่เป็นเบาหวานมีค่า HbA1c และ blood glucose สูงกว่ากลุ่มที่ไม่เป็นอย่างชัดเจน ทั้ง median และ range ของกล่องเลื่อนสูงขึ้นทั้งคู่ ซึ่งสอดคล้องกับหลักการแพทย์ที่ใช้ค่าเหล่านี้เป็นเกณฑ์วินิจฉัยเบาหวานโดยตรง

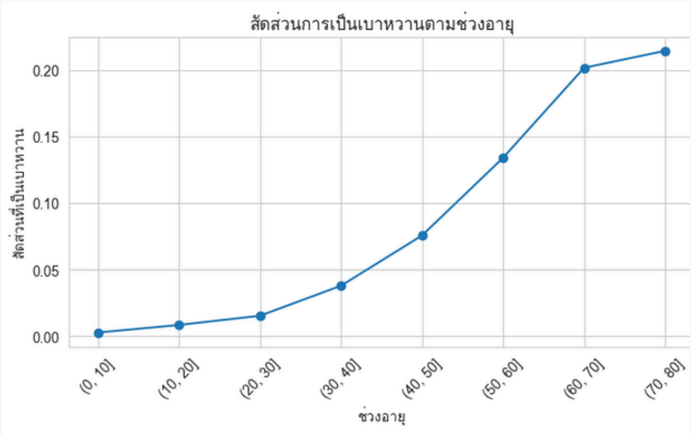
ข้อมูลไม่สมดุลระหว่างสองกลุ่ม (ต้องจัดการก่อนสร้างโมเดล) แต่ในทางกลับกัน ตัวชี้วัดทางคลินิกอย่าง HbA1c และ glucose กลับมีความสามารถแยกกลุ่มได้ชัดเจนมาก ซึ่งเป็นสัญญาณที่ดีว่าโมเดลน่าจะทำนายได้แม่นยำถ้าจัดการเรื่อง imbalance ได้ดี

EDA (2/2)

พฤติกรรมการสูบบุหรี่ อายุ และปัจจัยคลินิกล้วนสัมพันธ์กับความเสี่ยง



กราฟ 4 · สัดส่วนเบาหวานตามประวัติสูบบุหรี่



กราฟ 5 · สัดส่วนเบาหวานตามช่วงอายุ



กราฟ 6 · Correlation Heatmap

Insight: ผู้ที่เคย/กำลังสูบบุหรี่มีสัดส่วนเป็นเบาหวานสูงกว่ากลุ่มไม่เคยสูบ และความเสี่ยงเพิ่มขึ้นตามช่วงอายุอย่างชัดเจนอายุที่มากขึ้น สัมพันธ์กับความเสี่ยงเบาหวานที่สูงขึ้นอย่างชัดเจน ส่วน Heatmap ยืนยันว่า glucose, HbA1c, age, bmi สัมพันธ์กับ diabetes มากที่สุดค่า correlation เป็นเพียงความสัมพันธ์เชิงสถิติ ไม่ใช่ความสัมพันธ์เชิงเหตุและผล ดังนั้นเราไม่สามารถสรุปได้ทันทีว่าตัวแปรเหล่านี้เป็น "สาเหตุ" ที่ทำให้เกิดเบาหวาน

สรุป

สรุป และก้าวต่อไป

จากการวิเคราะห์ข้อมูลพบว่า อายุ เป็นปัจจัยที่ความเสี่ยงเบาหวานเพิ่มขึ้นชัดเจนที่สุด และได้รับการยืนยันด้วยค่าสถิติร่วมกับ glucose, HbA1c และ bmi ส่วนพฤติกรรมการสูบบุหรี่ยังต้องวิเคราะห์เพิ่มเติม ทั้งนี้ข้อมูลมีลักษณะ imbalanced ระหว่างกลุ่มเป็น/ไม่เป็นโรค ซึ่งเป็นประเด็นสำคัญที่ต้องจัดการในขั้นตอนสร้างโมเดลต่อไป



ก้าวต่อไป

- สร้างโมเดลทำนายความเสี่ยงเบาหวาน
- จัดการ class imbalance และเปรียบเทียบโมเดล
- ประเมินผลด้วย metric ที่เหมาะกับข้อมูลไม่สมดุล (เช่น recall, F1, AUC)

Colab link : https://colab.research.google.com/drive/12yncnUsZLkXPeEovgTwXNsovYEbw8tR1?usp=sharing

HealthSense

Thank you

Q&A

CP462 · INTRODUCTION TO DATA SCIENCE

นายวัชรพงศ์ มาลัง 67102010174
นาย นราธิป สุวณิชย์ 67102010517