Checkpoint โครงงาน

ชื่อหัวข้อโครงงาน

HealthSense: Predicting Chronic Disease Risk from Daily Lifestyle

สมาชิก

1. นายวัชรพงศ์ มาลัง รหัส 67102010174
2. นาย นราธิป สุวณิชย์ รหัส 67102010517

ระบุปัญหาที่ต้องการแก้ไขด้วยข้อมูล

โรคเรื้อรัง เช่น เบาหวาน ความดันสูง โรคหัวใจ เป็นสาเหตุการเสียชีวิตอันดับต้น ๆ และหลายโรคป้องกันได้ถ้าปรับพฤติกรรม แต่คนส่วนใหญ่มักไม่รู้ตัวจนกว่าจะป่วยแล้ว

โครงงานนี้จึงอยากทำนายว่าแต่ละคนมีโอกาสเป็นโรคเบาหวานหรือไม่ จากข้อมูลพื้นฐาน ประวัติสุขภาพ การสูบบุหรี่ และค่าตรวจสุขภาพ เพื่อให้รู้ตัวและปรับพฤติกรรมได้ก่อนป่วยจริง

ใครได้ประโยชน์ ถ้าโมเดลทำนายได้ดีจะนำไปใช้ตัดสินใจเรื่องอะไร

ผู้ได้ประโยชน์	นำไปตัดสินใจเรื่อง
ประชาชนทั่วไป	ประเมินความเสี่ยงของตัวเอง แล้วตัดสินใจปรับพฤติกรรมหรือไปตรวจก่อนป่วย
หน่วยงานสาธารณสุข	คัดกรองกลุ่มเสี่ยงสูง และเลือกพื้นที่/กลุ่มที่จะส่งทีมไปตรวจเชิงรุก
บริษัทประกันสุขภาพ	ประเมินความเสี่ยงของลูกค้า และออกแบบโปรแกรมส่งเสริมสุขภาพ

ถ้าโมเดลใช้ได้ดี จะช่วยให้ตรวจพบผู้ป่วยได้เร็วขึ้น และมีคนเข้ารับการตรวจคัดกรองก่อนมีอาการมากขึ้น

ต้องใช้ ML จริงไหม?

คิดว่าควรใช้ เพราะ

- ความเสี่ยงเบาหวานมาจากหลายปัจจัยพร้อมกัน เช่น อายุ BMI ความดัน โรคหัวใจ และค่าน้ำตาล จากกราฟ correlation ไม่มีตัวแปรไหนที่สัมพันธ์กับ diabetes เกิน 0.42 จึงใช้เกณฑ์ตัวเดียวแยกกลุ่มให้ชัดไม่ได้
- ข้อมูลมีมากพอ (96,146 แถวหลังทำความสะอาด)
- อยากได้ผลเป็นระดับความเสี่ยงของแต่ละคน เพื่อนำไปจัดลำดับกลุ่มเสี่ยง

แต่มีข้อสังเกตว่า HbA1c_level และ blood_glucose_level เป็นค่าที่แพทย์ใช้วินิจฉัยเบาหวานอยู่แล้ว ถ้าใช้กฎง่าย ๆ เช่น HbA1c ตั้งแต่ 6.5 ขึ้นไป อาจได้ผลดีพอสมควรอยู่แล้ว ใน Phase 2 จึงจะสร้างโมเดลพื้นฐาน (เช่น

Logistic Regression) มาเทียบก่อน และลองทั้งแบบที่ใช้และไม่ใช้สองค่านี้ เพราะเป้าหมายคือทำนายก่อนมีอาการ

คำอธิบายเกี่ยวกับชุดข้อมูล

แหล่งที่มา

Kaggle: Diabetes Prediction Dataset https://www.kaggle.com/datasets/iammustafatz/diabetes-prediction-dataset

ชุดข้อมูลนี้เกี่ยวกับอะไร มีจำนวนข้อมูลเท่าไร

ชุดข้อมูลนี้เป็นข้อมูลทางการแพทย์และประชากรของผู้ป่วย ใช้ดูว่าแต่ละคนเป็นเบาหวานหรือไม่ มีข้อมูลเพศ อายุ ประวัติความดันสูงและโรคหัวใจ ประวัติการสูบบุหรี่ และค่าตรวจ (BMI, HbA1c, ระดับน้ำตาลในเลือด) มีทั้งหมด 100,000 แถว 9 คอลัมน์ (1 แถวคือผู้ป่วย 1 คน) หลังลบแถวซ้ำ 3,854 แถว เหลือ 96,146 แถว

ตัวอย่างตารางข้อมูล

gender	age	hypertension	heart_disease	smoking_history	bmi	HbA1c_level	blood_glucose_level	diabetes
Female	80.0	0	1	never	25.19	6.6	140	0
Female	54.0	0	0	No Info	27.32	6.6	80	0
Male	28.0	0	0	never	27.32	5.7	158	0
Female	36.0	0	0	current	23.45	5.0	155	0
Male	76.0	1	1	current	20.14	4.8	155	0

(5 แถวแรกของข้อมูลก่อนทำความสะอาด)

ระบุ feature และ target

Feature มี 8 ตัว

Feature	ความหมาย	ชนิด
gender	เพศ (Male/Female/Other)	Categorical
age	อายุ (0-80 ปี)	Numeric
hypertension	เป็นความดันสูงหรือไม่	Binary
heart_disease	เป็นโรคหัวใจหรือไม่	Binary
smoking_history	ประวัติการสูบบุหรี่	Categorical
bmi	ดัชนีมวลกาย	Numeric
HbA1c_level	น้ำตาลสะสม 2-3 เดือน	Numeric
blood_glucose_level	น้ำตาลในเลือดขณะตรวจ	Numeric

Target คือ diabetes (1 = เป็นเบาหวาน, 0 = ไม่เป็น)

ระบุ type of learning / task

เป็น Supervised Learning เพราะมี label คือ diabetes และเป็นงาน Classification แบบ 2 คลาส (เป็น / ไม่เป็นเบาหวาน)

ข้อมูลไม่สมดุล คนส่วนใหญ่ไม่เป็นเบาหวาน จึงต้องจัดการเรื่อง class imbalance และดู recall, F1, AUC ประกอบ ไม่ดูแค่ accuracy